



中华数据库
行业协会

大众点评数据架构之道

苗发平

2013-11-05





中华数据库
行业协会 大众点评
dianping.com



中华架构师大会

ARCHITECT CONFERENCE CHINA

主办单位：中华数据库行业协会

承办单位：上海热璞网络科技有限公司

协办单位：UPYUN、MEMBLAZE、唯品会

捐助单位：INTEL、世纪互联、天地祥云

指导单位：上海市杨浦区大学生创业示范园





上海热璞网络科技有限公司拥有一批多年在核心业务系统打拼的资深老兵，他们是一群狂热的技术专家，对各行业业务理解透彻，能够快速解决客户当下疑难，高效帮助客户规避未来可能发生的故障，借助技术和经验降低成本，我们的团队价值远大于您所想。

我们积极倡导并遵循开源精神，经过多年数据库软件项目的历练，建立了成熟的项目规划、实施与交付体系，能够为用户提供包括解决方案、架构设计、测试、实施、上线、运维、培训在内的一站式服务。

**做客户长期的合作伙伴
并成为市场上最令人信赖的专业供应商**

一站式服务

数据库服务：

去IOE规划与实施、高可用实施、性能诊断优化、故障解决、灾难挽救、数据迁移、数据同步、日常维护、系统健康检查、数据库升级等

运维服务：



5*8或7*24技术支持、维护管理服务、人员驻场、监控软件、现场知识培训、专题交流、远程（电话/在线）诊断、现场故障处理、定期巡检、升级实施

培训服务：

量身定制培训、认证培训、年度计划培训、按班培训



天眼分布式监控系统



天眼主要特点:

- 丰富的网络、系统、应用性能监控及可用性监控
- 支持Agent、SNMP等监控架构
- 支持自动发现网络设备、主机等
- 支持分布式监视和Web集中管理平台功能
- 支持对主机、网络设备的批量执行命令
- 多元化的预警媒体,例如Email, SMS, 自动拨打电话等
- 用户安全认证和灵活的授权方式
- 通过Web界面设置或查看监视结果
- 提供丰富的监控模板
- 拥有灵活的用户安全认证和授权方式
- 支持自定义的监控脚本,包括Shell、Python、Perl、PHP


Agenda



中华数据库
行业协会 大众点评
dianping.com

- 引子
- 数据架构@点评
- 实时查询分析@点评
- 工具与自动化运维

About me



中华数据库
行业协会 大众点评
dianping.com

- 负责点评数据/存储平台
- 数据库、缓存、数据仓库的架构、运维、开发支持etc
- HW -> TC -> DP
- 开发 -> DBA/运维
- Weibo : @DP大发发

About dianping



中华数据库
行业协会 大众点评 dianping.com

- 中国领先的本地生活信息及交易平台
- 商户信息、消费点评、消费优惠、团购、电子会员卡、餐厅预订（O2O）
- 8000w/30亿
- 600w+
- 2800w+

Agenda

- 引子
- 数据架构@点评
- 实时查询分析@点评
- 工具与自动化运维


数据架构@点评

- MySQL高可用
- 缓存架构
- 业务拆分与泳道隔离
- 其它

数据架构@点评

- MySQL高可用
- 缓存架构
- 业务拆分与泳道隔离
- 其它

DB Arch




MySQL高可用

- MySQL通过MMM实现HA高可用，秒级故障转移
- DDL操作是通过MMM将数据库Offline，进行离线维护
- 2010年开始用，比较熟悉，修改了不少bug，坑踩的差不多了


MMM

- MySQL Master Master Replication Manager (by Google)
- Perl
- Message between Monitor & Agent
- Auto Failover for M/S
- VIP
- MMM is NOT For:
 - Router
 - Load Balance


MMM




MMM




MMM




MMM




MMM




MMM



MMM



MMM



MMM Issues

- set read_only is difficult on busy server
- set read_only will be blocked by long running SQL
- Writer VIP cannot be accessed when slave is far behind master
- BUG: Net::ARP package updated (1.0 → 1.0.8)

You can find

<https://github.com/cenalulu/mysql-mmm>

数据架构@点评

- MySQL高可用
- 缓存架构
- 业务拆分与泳道隔离
- 其它

两级缓存

- Ehcache (一级)
 - ✓ Java内置
 - ✓ 速度快 (比memcached快x0倍以上)
 - ✓ 高并发
 - ✓ 使用灵活
- Memcached (二级)
 - ✓ 稳定
 - ✓ 分布式 (通过客户端实现)
 - ✓ 网络
 - ✓ 简单易用

缓存雪崩


- 逻辑原因
 - ✓ 过期
 - ✓ Value异常（如超过1M）
 - ✓ 内存不够
 - ✓ 清缓存
- 物理原因
 - ✓ 宕机
 - ✓ 网络异常
 - ✓ 其它

- 通过 “热点缓存” 解决逻辑原因可能导致的雪崩问题
- 同一个对象缓存两份（ A/B ），一般情况下只读 A ，如果为null ，查询service或数据库 ，返回前其它请求均访问B
- B为一级缓存 ，只存在于jvm ，有效期较长
- A更新时同步更新B


Memcached双写

- 业务拆分与隔离，导致一致性hash环较小
- memcached一旦击穿，大量访问压到数据库
- 通过 “memcached双写+一致性Hash” 解决物理原因导致缓存不可访问
- 相对于数据库，memcached成本较低


Memcached双写



Memcached双写



Memcached双写




数据架构@点评

- MySQL高可用
- 缓存架构
- 业务拆分与泳道隔离
- 其它

业务特点

- 业务比较复杂，如几乎所有业务都要调用商户/点评/用户等基础服务
- 业务重要程度不同，避免核心业务受到影响
- 因为诸多原因，数据库拆分不够细，依然承载一些较复杂访问，容易出问题


之前架构



泳道隔离

- 泳道隔离：一个用户请求，在一个独立业务域内流转，同一个app实例不被多个业务共用
- 泳道包括web、service、缓存、数据库等，泳道之间尽可能解耦，彼此间弱依赖，并进行适度容错
- 跨业务/模块访问通过service接口调用
- 泳道内读，跨泳道写，数据保证最终一致性
- 泳道按业务功能拆分并独立部署，如商户/点评/用户/订单/券/支付等

隔离后架构



数据库拆分

- 划出拆分边界，切断对外耦合
- 部署新数据库集群，先迁移读流量
- 停服务后迁移写流量
- 如果只涉及一个service，可以将service只减为一台，然后修改配置到新集群，保证业务不可用时间降到最短
- 通过TABLE_STATISTICS + tcpdump 监控是否依然存在读写

数据架构@点评

- MySQL高可用
- 缓存架构
- 业务拆分与泳道隔离
- 其它

其它原则（1）

- 除两级缓存外，部分页面通过varnish做整体缓存
- 个性化数据（如点评/频道POI数据等）使用MongoDB存储，DDL不再是问题
- 大字段单独存放，千万级大表基本没做水平拆分
- 核心业务使用PCI-E Flash卡
- 充分利用搜索，提升性能和安全性

其它原则（2）

- 读写分离，实现简单的Load Balancer
- 数据按业务线/模块垂直拆分，模块间禁止关联查询
- 模块内部允许适度JOIN，但须经DBA审核
- 少量极大表进行了水平分拆，不同维度间通过队列同步

Agenda

- 引子
- 数据架构@点评
- 实时查询分析@点评
- 工具与自动化运维

实时查询分析需求

- 产品人员产品探索
- 仓库开发建模
- BI人员快速数据分析
- 临时报表等

查询分析产品

- Hadoop/Hive
- Impala
- Drill
- Spark/Shark
- InfoBright/InfiniDB/GreenPlum ...

产品选型对比

产品特性	Infobright (ICE)	InfiniDB (CE)	GreenPlum (CE)
接口类型	MySQL	MySQL	PostgreSQL
压缩比	高	低	中
列存储	Yes	Yes	Yes
多核查询支持	No	Yes	Yes
Hadoop支持	No	Yes	Yes
DDL/DML支持	No	Yes	Yes
Free	Yes	Yes	Yes

TPC-H (10G)-1

Load 时间及压缩率测试


时间单位: 秒	Infobright	InfiniDB	Greenplum quicklz	Greenplum zlib6
导入时间	1393 秒	603 秒	302 秒	504 秒
文件大小	1.71G	11.93G	8.32G	2.48G

TPC-H (10G)-2

Query 执行时间测试

时间单位: 秒	Infobright	InfiniDB	Greenplum quicklz	Greenplum zlib6
Query 1	203.01	32.03	48	50.21
Query 2	2856.23	<u>32.85</u>	<u>3.61</u>	<u>4.06</u>
Query 3	32.52	9.43	7.47	8.62
Query 4	2091.22	Error1	5.90	5.55
Query 5	38.83	<u>5.46</u>	7.57	8.49
Query 6	28.95	8.13	5.412	6.33
Query 7	79.29	10.17	119.99	83.86
Query 8	26.90	6.52	12.08	11.13
Query 9	61.65	Error1	41.43	60.47
Query 10	630.31	Error1	20.55	9.12
Query 11	13.56	1.08	\n	\n
Query 12	215.26	9.31	10.66	7.55
Query 13	188.76	18.24	17.89	16.76
Query 14	70.76	2.35	5.31	6.33
Query 15	33.2	2.85	11.56	13.98
Query 16	36.76	4.59	5.50	5.13
Query 17	> 1hr	<u>16.43</u>	<u>8.63</u>	<u>9.29</u>
Query 18	215.59	9.29	144.96	165.78
Query 19	190.9	<u>34.26</u>	16.23	10.33
Query 20	> 1hr	11.82	<u>18.99</u>	<u>16.35</u>
Query 21	> 1hr	Error2	<u>85.97</u>	<u>53.88</u>
Query 22	> 1hr	16.56	<u>10.23</u>	<u>18.75</u>

存储扩展问题



Agenda

- 引子
- 数据架构@点评
- 大数据@点评
- 工具与自动化运维

- 标准化（基础）
- 工具化
- 变更与权限控制
- 监控（自主开发+zabbix）
- SQLReview

变更和权限控制

- 政府、市场
- 从DBA帮你做变为DBA授权给你做
- 临时查询权限自助申请与回收（准入放开+跳板机+定期审计+黑名单机制）
- 线上数据变更DBA一键审核，自主发布
- 手机审核，随时随地处理

- tcpdump+pt-query-digest
- highcharts

SQL监控

展开查询条件

Time Range 2013-11-04 00:00:00 to 2013-11-04

Machine Group


Top N 10 15 20

查看报表

Top 10 QPS on

Rank	Command	QPS	Byte Rate	Query Time(ms)			Value Size(Byte)			Action
				Avg	95%	Max	Avg	95%	Max	
	set autocommit=?	3664	57KB/s	0.181	0.561	4210.741	16	16	16	Detail
1	SELECT 3 columns FROM WHERE a.dogroupid in(??)	377	89KB/s	0.499	0.218	1407.600	242	147	9166	Detail
2	SELECT 3 columns FROM WHERE status = ? and d.dogroupid in(??)	284	61KB/s	0.458	0.233	980.095	221	153	15094	Detail
3	SELECT 7 columns FROM a WHERE d.dogroupid in(??)	226	61KB/s	0.412	0.198	2206.228	276	191	11763	Detail
4	SELECT 3 columns FROM WHERE d.dogroupid in(??)	195	28KB/s	0.612	0.232	2375.286	149	102	4443	Detail
5	SELECT 2 columns FROM WHERE a.dogroupid in(??) ORDER BY ismain desc	194	53KB/s	0.896	0.640	1706.150	280	184	9260	Detail
6	SELECT 55 columns FROM a left join b on a.dogroupid=c.dogroupid left join c on a.dogroupid=d.dogroupid WHERE a.dogroupid in(??)	182	222KB/s	0.910	0.543	2203.977	1248	1221	3385	Detail
7	SELECT 5 columns FROM a WHERE a.dogroupid in(??)	178	49KB/s	0.508	0.208	3924.360	280	183	9259	Detail
8	SELECT 18 columns FROM a WHERE a.dogroupid = ? and a.dogroupid in(??) ORDER BY a.dogroupid desc, a.dogroupid;	174	101KB/s	1.166	0.835	2525.566	596	502	9467	Detail
9	SELECT 7 columns FROM a WHERE a.dogroupid in(??)	156	49KB/s	0.459	0.247	1159.436	323	207	9226	Detail

Total Statistics



Memcached监控


Total Statistics Top10 CMD Single Query Stat

Time Range 2013-11-04 00:00:00 to 2013-11-04

Machine Group 10.10.10.11211

查看报表

Name	Query Per Second	Avg Traffic Rate	Query Time(ms)			Value Size(Byte)			Miss Ratio
			Avg	95%	Max	Avg	95%	Max	
Total	2883/s	2937382B/s	11.24	33.24	4595.49	1019	13853	83138	17%



SQLReview

- ibatis
- Git hook

SQLReview



待审核 SQL

苗发平

待办事项 (1)

待审核SQL (112) | 退出

项目名: 【XXXXXXXXXX】

路 径: nulldeal-service-dal/src/main/resources/config/sqlmap/DealContract.xml

SQL

7614 getCostByDealId

2013-11-04 16:55:01

OLD:

NEW:

SELECT Cost FROM XXXXXXXXXX
WHERE DealId = ? LIMIT 1

(XXXXXX 0)

审核



完 成

[审核记录](#)

7615 getCostByDealIds

2013-11-04 16:55:01

OLD:

NEW:

SELECT DealID, Cost FROM XXXXXXXXXX
WHERE DealId IN
<iterate open="(" close=")" conjunction="," property="dealIds">
#dealIds[]#
</iterate>

(XXXXXX 0)

审核



完 成

[审核记录](#)

- 权限管理不再繁琐
- 变更和发布效率大增，DBA不再苦逼
- 对异常SQL与缓存问题的发现缩短到5分钟内
- SQL代码merge时，自动通知DBA审核，沟通成本大减

协办单位-唯品会

乘着电商大潮 引领技术之巅

唯品会（纽交所股票代码：VIPS）技术中心简介：VIPSHOP (www.vipshop.com), 一家以限时抢购、品牌折扣为独特商业模式的B2C购物网站，其使命是建立全面完善的电子商务平台，为合作伙伴和消费者提供最佳的用户体验。截至2013年11月，技术中心规模超过500人，由来自全国乃至世界顶尖互联网技术骨干带领，为实现技术驱动业务，现诚邀各技术牛人加盟，共创一流电商平台。



招聘职位：

- 1、Java架构师/高级工程师/工程师
- 2、PHP架构师/高级前端开发工程师
- 3、测试架构师
- 4、iOS高级工程师/工程师
- 5、高级ETL开发工程师/数据分析师/数据挖掘工程师
- 6、推荐系统算法开发工程师
- 7、运维资深工程师
- 8、系统安全工程师/web安全工程师（黑盒/白盒）；


有意向的可发简历到circle.wang@vipshop.com，
或致电王小姐020-22330078

狭路相逢勇者胜！
我们等的就是——你！！！！

协办单位-MEMBLAZE



颠覆技术传统 突破 I/O 极限



PBLAZE III PCIe闪存卡

- 800,000 IOPS
服务器数据处理能力获万倍提升
- 3.2GB/s 顺序读
极致数据吞吐速度，性能爆发式增长
- 2.5GB/s 顺序写
极致数据吞吐速度，性能爆发式增长
- 15μs 延迟
超低延时，保障前端应用平滑顺畅
- 1MB 内存占用
降低内存开销，主机运算更快
- 50% 降低 CPU 占用
主机资源消耗更低，服务器运算能力大增

北京亿恒创源科技有限公司
北京市海淀区上地信息路2号国际创业园
400-650-7995
contact@memblaze.com
http://www.memblaze.com

应用	数据库	大数据	CDN	搜索引擎
2,000-10,000 单机IOPS达2000-10000	120X TPS提升20倍	120% 集群效率提升20%	150% 提升计算效率50%	150% 提升效率

协办单位-又拍云

upyun 又拍云存储

又拍云存储主要为用户提供静态文件云存储、云处理、云分发三块业务，我们致力于让您的创业变得简单。凭着安全、稳定、快速的产品特性，当前已有 30000 多家互联网企业选择使用又拍云存储的服务。客户包括：会说话的汤姆猫，捕鱼达人，one·一个，百姓网，知乎，36 氪，雪球财经等众多知名企业。

产品优势



省钱

按需付费，用多少付多少，相比传统CDN按带宽计费成本更低。



省心

业务快速增长，只需扩展相应的又拍云套餐即可，可以把更多的精力放在产品运营上。



更安全


上传文件自动3备份，不用担心数据丢失问题。



多功能

CDN加速，自定义30种缩略图，token防盗链，图片水印，音视频处理等众多实用新功能。

客户案例



捐助单位-INTEL



Apache Hadoop* 英特尔分发版 为新一代数据分析所设计的开放平台

强大的企业级Hadoop发行版，
HBase改造和增强，为Hadoop提供实时数据处理能力

利用最新技术进行优化，
针对行业功能增强，应对不同行业的大数据挑战

Intel Hadoop Manager 部署、配置、管理、性能和监控					
Name	Platform	Configuration	Performance	Management	Monitoring
部署和配置工具	跨平台	跨平台	跨平台	跨平台	跨平台
性能优化工具	跨平台	跨平台	跨平台	跨平台	跨平台

- 侧边实时分析
- 增值管理支持部署与监控
- 附加安全与合规控制
- 英特尔优化整体解决方案架构，分布、存储、网络、计算
- 特定行业的定制化
- 业界领先性能



TD 性能和性能提升



*性能数据来源于该项目的内部测试。在性能测试中使用的软件及其负载可能为英特尔处理器器的性能进行了优化。诸如SYSmark和MobileMark等测试均基于特定计算机系统、硬件、软件、操作系统及功能。上述任何要素的变动都有可能導致测试结果的变化。请参考其他性能及性能测试（包括结合其他产品使用时的运行性能）以对产品进行性能评估。

更多信息欢迎访问<http://www.intel.com/performance>

捐助单位-世纪互联

北京世纪互联宽带数据中心有限公司（21ViaNet Group, Inc. 简称世纪互联）是中国目前规模最大的电信中立互联网基础设施服务提供商。我们为客户提供业界领先的服务器及网络设备托管服务，并通过优质的网络互联服务（interconnectivity），帮助企业全面提升其互联网基础设施的性能、可用性和安全性。此外，我们的服务范围还涵盖管理式网络服务（managed network services），致力于帮助客户通过广泛的数据传输网络和特有BroadEx®智能路由技术在互联网上更快捷、更可靠地传输数据。

目前，世纪互联在国内42个城市运营81家数据中心，一共管理有超过11917个机柜，覆盖超过68000个服务器。世纪互联独立于电信运营商的数据传输网络包括超过458个服务提供点，每个服务提供点指代由一个地方链接其他网络领域的连接点。自2012年12月31日起，公司拥有1972名客户，其中包括许多中国与国外顶尖公司，这些公司在中国境内不同行业覆盖度极广。世纪互联客户包括互联网公司、政府实体、蓝筹企业以及中小型企业。

• **主营业务：** IDC服务、专线接入、系统集成、网络信息软件开发、数字地产项目开发、基于云计算的下一代数据中心服务（**Internet Computing Service**）

• 国务院发展中心、国家信息产业部、国家商务部、国家发改委等单位支持探索中国首家“离岸数据中心外包服务保税园区”课题研究及项目试点

• 中国第一家拥有大型电信级机房的电信中立数据中心服务商

• 中国第一个汇聚六大运营商网络资源的**BGP**平台服务商

• 中国第一个通过**ISO**认证的数据中心

• 中国第一个提供**SLA**的服务商

中国第一个建造集装箱式数据中心

2014中华数据库与运维安全大会

- ◆ 会议名称：中华数据库与运维安全大会
- ◆ 会议时间：2014年05月24日（星期六）
- ◆ 报名周期：2014年02月14日 – 2014年03月15日
- ◆ 主题数量：上午4个演讲主题，下午10个演讲主题
- ◆ 报名官网：<http://dtcc.mysqllops.com/>

报名时间	普通票（A类）	普通票（B类）	普通票（C类）
2014年02月14日-2014年03月25日	免费	300块人民币，提供：VIP座席，会务中餐	600块人民币，提供：VIP座席，会务中餐，会务晚宴
2014年04月25日-2014年04月30日	200块人民币	400块人民币，提供：VIP座席，会务中餐	700块人民币，提供：VIP座席，会务中餐，会务晚宴
2014年05月01日-2014年05月20日	400块人民币	500块人民币，提供：VIP座席，会务中餐	800块人民币，提供：VIP座席，会务中餐，会务晚宴
2014年05月21日-2014年05月24日	600块人民币	700块人民币，提供：VIP座席，会务中餐	1000块人民币，提供：VIP座席，会务中餐，会务晚宴

2014中华数据库与运维安全大会

签到				
致 辞				
主 持 人 阿里巴巴集团 核心系统部 资深专家 余锋 @淘宝褚霸				
主会场	演讲主题	演讲嘉宾	公司名称	职位/职称
	待更新	田冰	圆通速递	高级总监
	待定			
	待更新			
	待定			
午餐时间				
主 持 人 阿里巴巴集团 核心系统部 资深专家 余锋 @淘宝褚霸				
运维安全 专场	演讲主题	演讲嘉宾	公司名称	职位/职称
	互联网金融风控与反欺诈	刘丹	人人网	安全中心负责人
	心的运维——被遗忘和误解的古老老运维方案	古雷	搜狐网	技术专家
	IT自动化运维之运维监控	李强	精硕科技	运维经理
	待更新	刘宇	百度	运维专家
	待定			
主 持 人 精硕科技（AdMaster） CTO 洪倍 @洪倍-手推车				
数据库 专场	演讲主题	演讲嘉宾	公司名称	职位/职称
	深入理解 MySQL Replication	宋利兵	甲骨文	MySQL研发工程师
	深入MySQL源码——Step by Step	何登成	网易杭州研究院	高级研发经理
	茶歇			
	待更新	陈福荣	腾讯互动娱乐事业群	高级工程师
	待更新	田发明	中国网络电视台	高级经理
	MySQL高可用架构之MMM在大众点评应用和改进	卢钧铁	大众点评网	高级DBA
18:20-18:40	抽奖奖品：一等奖 待定；二等奖 待定；三等奖 待定；			
19:00-	会议晚宴：会议嘉宾、捐助者、赞助商、赞助商邀请的客户代表、拥有晚宴邀请函的参会者			

Q&A



中华数据库
行业协会 大众点评
dianping.com

Thanks