



BEIJING 2017

美团点评旅游推荐系统的演进

郑刚



促进软件开发领域知识与创新的传播



关注InfoQ官方信息
及时获取QCon软件开发者
大会演讲视频信息



扫码，获取限时优惠

ArchSummit
全球架构师峰会 2017 [深圳站]

2017年7月7-8日 深圳·华侨城洲际酒店

咨询热线：010-89880682

QCon

全球软件开发大会 [上海站]

2017年10月19-21日

咨询热线：010-64738142

- 2015年至今 美团点评酒旅事业群
 - 负责酒旅搜索排序推荐
 - 负责酒旅数据仓库和数据产品建设
- 2014年之前 美团网技术部数据组
 - 参与数据平台搭建
 - 负责全平台数据仓库和数据产品建设
- 2011年 百度电子商务事业部
 - 有啊商城的开发
- 2010年毕业于中科院计算所



Outline

- 美团点评酒旅业务简介
- 基于用户画像的召回策略演进
- 基于L2R的排序策略优化
- 从海量大数据的离线计算到高并发在线服务的推荐引擎架构设计
- 推荐在美团点评酒旅的应用实践

人工智能应用

Critical
Digital World

Critical
Physical World

Non-Critical
Digital World

Non-Critical
Physical World

新美大酒旅


国内发展最快的一站式综合住宿服务平台
国内最大的在线门票交易平台

• 2016年美团点评酒店覆盖量与间夜量



2016年全年，美团点评双平台酒店间夜量超**1.3亿**，高星级酒店间夜单月增速最高达**300%**，酒店商家**32万**。

• 2016年美团点评票务销售量



2016年全年，
美团点评门票销售**6700万张**。

2016年全年，
机票销售**200万张**。



2016年全年，
火车票销售**800万张**。

新年新高度！

2017年1月31日

美团点评景点门票

单日交易额 新纪录

1.14 亿

单日入园人次超过

106 万

比去年春节同期增长超过**100%**



美团点评

国内最大的在线门票交易平台
为全国超过2万个景区景点提供业界领先的专业票务解决方案

酒旅搜索推荐

2015Q3 组建推荐团队
2015Q4 周边游频道内推荐
2016Q1 搜索少/无结果推荐
2016Q2 详情页推荐
2016Q3 酒旅交叉推荐
2016Q4 点评旅游推荐

酒店住宿

境内度假

境外度假

大交通

搜索/推荐


数据挖掘

数据产品

酒旅数据仓库

集团数据平台

旅游推荐产品形态



旅游场景下用户兴趣点不明确，频道内超过50%订单来自推荐

旅游推荐面临的问题



本异地差异大



推荐形式多样



季节性明显



需求个性化

本异地差异大



— 猜你喜欢 —

故宫博物院(5A) 12.6km
4.8分 | 25546人评价
门票、套餐、线路游 等优惠
¥5 起 已售150856

颐和园(5A) 18.5km
4.6分 | 6200人评价
门票、套餐、线路游 等优惠
¥25 起 已售14312

八达岭长城(5A) 56.4km
4.8分 | 4393人评价
门票、套餐、线路游 等优惠
¥35 起 已售79610

圆明园(4A) 15.4km
4.7分 | 6572人评价
门票、套餐、线路游 等优惠
¥21.9 起 **立减1元** 已售28552

呀路古热带植物园(3A) 40.2km



— 猜你喜欢 —

北京欢乐谷(4A) 15.6km
4.7分 | 93655人评价
门票、套餐、线路游 等优惠
¥58 起 已售104885

呀路古热带植物园(3A) 40.2km
4.6分 | 6202人评价
门票、套餐、线路游 等优惠
¥45 起 已售54912

活的3D博物馆 2.7km
4.4分 | 11383人评价
门票 等优惠
¥38 起 已售25698


太平洋海底世界(3A) 18.4km
4.4分 | 25212人评价
门票、线路游 等优惠
¥66.7 起 **立减10元** 已售23442



超过30%订单来自异地请求

常驻城市!=浏览城市

推荐形式多样



景点下有大量相似门票,不适合按Deal样式展现

跟团游、景酒套餐关联多个景点,不适合按POI样式展现

季节性明显



冬季温泉订单占比超过20%,
而夏季不到7%

需求个性化



北京亲子游玩群正在热烈讨论 点击加入

“亲子游”是宝宝成长中最温馨永久的记忆，也是父母与孩子间的良好交流渠道。小编特别整理“潮爸潮妈都说好”的亲子游好去处，赶快携子出游吧！

全部 1岁及以上 4岁及以上 6岁及以上



一个人吃狗粮，两个人玩浪漫。趁着阳光正好，微风不噪，带上你心爱的TA，一起去赏古迹、泡温泉、逛展览，解锁“城会玩”新技能！到游乐场里，撒泼打滚“嗨翻天”！来山水田园，花式“拍美照”！

全部 酒店+景点 嗨翻天 拍美照



用户人群
时间地域场景
内容形态

基于用户画像的召回策略演进




热销策略

基于Deal所在城市统计分城市热销



分类	场景	召回策略
本地需求	常驻城市=浏览城市 (北京人浏览北京)	当地用户购买的热销POI
异地需求	常驻城市!=浏览城市 (重庆人浏览北京)	异地用户购买的热销POI (所有非北京人购买的热销POI)




$$deal_score = \sum_{i=1}^{28} p_i * \alpha^i$$

销量按时间衰减

热销策略

•精确统计POI销量

- Deal -> POI
- POI售卖数据不准
- 客户端埋点



POI详情页
F_poiid



DEAL详情页
F_poiid



下单页
F_poiid



用户画像

$$h_w(x) = P(y = 1|x; w) = \frac{1}{1 + e^{-wx}}$$

•模型

- LR：预测常驻城市与某维度城市相等的概率

•样本

- 调查问卷

•特征

- 注册城市
- 注册手机号
- 手机定位城市
- 浏览城市
- 消费城市：团购、电影、外卖
- 接受短信手机号




用户历史行为强相关策略

- 热销策略能区分本异地用户差异
- 不能对具体用户个性化推荐

• 用户一个月内浏览、收藏的 POI/Deal

• 越实时权重越高



Location-Based策略

- 冷启动



- 新POI
- 新用户

- 区域消费热门POI

- 5KM范围内的热销POI

- 区域购买热门POI

- 5KM范围内的用户购买的POI
- 回龙观附近没有POI



协同过滤

•Item CF

•基于POI浏览行为

•POI相似度每天离线更新，User浏览POI行为实时更新


•相似度改进：时间序列衰减

•基于用户搜索行为


•基于搜索后浏览POI行为构造<Query,POI>矩阵，计算POI相似度

•User CF

•loglikelihood ratio



$$w_{ij} = \frac{\sum_l N_{ijl} * \alpha^l}{\sqrt{|N(i)| |N(j)|}} (i < j)$$



基于用户画像的推荐

用户标签偏好*标签权重*POI标签偏好*POI销量

•基础属性

•性别、年龄、职业

•人群属性

•有车：汽车保养
•宅男：外卖
•情侣：电影
•亲子：儿童乐园
•旅游达人：酒店旅游交通


•推荐

•基于用户标签计算POI标签
•精确匹配：给亲子类用户推荐亲子类POI
•模糊匹配：基于标签计算用户和POI相似度

$$D(P \parallel Q) = \sum_{x \in X} P(x) \log \frac{P(x)}{Q(x)}$$

标签在POI维度的分布

标签在用户维度的分布



召回策略演进过程

本异地热销策略

历史行为强相关

- 浏览未购买
- 收藏未购买

Location-Based

- 区域热门消费
- 区域热门购买

协同过滤

- Item CF
- POI CF
- Query CF
- User CF
- LLR

基于用户画像的推荐

- 精确匹配
- 模糊匹配

基于L2R的排序策略优化



机器学习流程



问题建模


•访购率为目标

- 只看点击率没有反映出交易属性
- 看最终收入
 - 消费受购买限制、退款条件等影响
 - 收入跟BD谈单毛利相关

•Pointwise L2R

- Pairwise性能问题
- NN做rank?

$$\text{每推荐用户收入} = \underbrace{\frac{\text{点击用户数}}{\text{推荐用户数}}}_{\text{有点行为比}} \times \underbrace{\frac{\text{支付用户数}}{\text{点击用户数}}}_{\text{访购率}} \times \underbrace{\frac{\text{消费用户数}}{\text{支付用户数}}}_{\text{访消率}} \times \text{每用户消费收入}$$



问题建模

•GBDT

- 非线性
- High Level特征多

•XGBoost

- 泰勒展开，利用了二阶导数信息
- 对数据预排序，性能更高

•多模型融合


- GBDT模型+FFM模型

Hypothesis:
$$h_M(x) = \sum_{m=1}^M \beta_m T(x; \Theta_m)$$

Loss Function:
$$\min_{h \in H} L(h) \equiv \min_{h \in H} \frac{1}{2} \sum_{i=1}^N (y_i - h(x_i))^2$$

Update Function:
$$\{\hat{\Theta}_m, \beta_m\} = \arg \min_{\Theta_m, \beta_m} \sum_{i=1}^N L(y_i, h_{m-1}(x) + \beta_m T(x; \Theta_m))$$

$$G_j = \sum_{i \in I_j} g_i \quad H_j = \sum_{i \in I_j} h_i$$
$$Obj = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T$$



问题建模



$$y(\mathbf{x}) = w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n \langle \mathbf{v}_{ij}, \mathbf{v}_{ji} \rangle x_i x_j$$

•FFM

- 矩阵分解+回归
- Low Level特征多

•情景推荐

- 发现特征关联关系
- 用户画像
- 上下文
- POI ID&属性



数据标注

样本关联

- global id: 串联展示、点击、下单

样本选择

- 时间窗口
- 过滤
- 样本迁移
- Skip above


样本采样

- 访购模型: 减少负样本
- 点击模型: skip above+2

样本权重

- 支付>下单>点击

特征工程



特征工程

•特征预处理


- missing value : 不需要处理
- position bias : COEC
- One-Hot Encoding ? 周几/小时/city id
- Normalize?

•召回策略特征化

- 销量拆分本异地
- User-POI行为 : 实时/长期
- GeoHash热销
- POI CF

•特征选择

- 特征在每棵树每个节点的信息增益之和





特征工程

•特征分析

- 分本异地统计转化率、销量
- 天气

•特征监控

- 覆盖率
- 值域范围
- 分布异常



特征	coverRatio			numValid		
	参考值	监控值	波动率	参考值	监控值	波动率
CLICKNET	0.931341	0.481258	0.483263	3271405	1745754	0.46636
DISTANCE	0.651660	0.033357	0.948812	13447	662	0.950770


模型训练

•模型训练

- 单机VS分布式
- 目标函数：binary:logistic
- 过拟合VS欠拟合
 - 样本大小&树的棵数
 - 样本和特征随机采样
- 模型复杂度：max_depth , min_child_weight

•通用离线训练工具

- 流程抽象化、组件化
- 提供公共组件，支持定制组件



效果评估&线上迭代

• 离线评估


- AUC
- logloss

• 在线评估

- ABTest：按UUID分流

• 线上迭代



- 模型更新
- 特征漂移：更新延迟




训练集表现	测试集表现	问题
<期望目标值	<期望目标值	Underfitting
>期望目标值	接近或略逊于训练集	合适
>期望目标值	远差于训练集	Overfitting

模型调试


模型Debug工具




从海量大数据的离线计算到高并发在线服务的推荐引擎架构设计



基础数据



应用数据



应用数据线上化-DataHub

- 特征抽取

- 统一特征抽取调度
- 精确控制数据导入速率，避免并发写压力过大

- 特征存储


- 数据压缩：Value String

- 特征管理

- 特征注册、特征监控




- 特征消费

- Client缓存：Direct Momery
- 异步化：Thrift Async




推荐引擎

- 召回
 - Booth : 场景
 - Strategy : Baseline
 - SelectRule : Location-Based
 - Selector : 区域热销POI
- Merge : 子策略融合
 - 调制
 - 分级
- 过滤
 - 通用过滤策略 : 黑名单
 - 针对某类召回策略 : 浏览未购买
- Rerank : 个性化排序
- Post Rerank



推荐引擎-Rerank





实时策略效果统计

数据源

Storm

数据存储

监控展示



推荐在美团点评酒旅的应用实践



推荐应用

美团/点评双平台

频道首页

- 品类区
- Banner
- 头条
- 人气区
- 猜你喜欢

搜索结果页

- 少结果推荐
- 无结果推荐

筛选结果页

- 筛选标签
- 异地召回

详情页

- 看了又看
- 附近景点
- 附近酒店



推荐应用

品类区



banner



周边游频道首页



人气区



角标



看了又看

景点POI详情页




酒旅交叉推荐



推荐应用

POI标签



筛选列表页

筛选异地召回




搜索少/无结果推荐

- 无结果推荐

- 查询改写
- Query CF
- Location-Based
- 热销POI

- 少结果推荐

- POI CF
- POI同品类推荐



总结

本异地差异大

- 基于常驻城市定义本异地
- 召回：热销区分本异地
- 排序：分本异地统计销量、转化率

推荐形式多样

- 基于埋点精确统计景点POI销量
- 游记攻略头条

季节性明显

- 销量加速
- POI标签

需求个性化

- 用户历史行为：浏览、收藏、搜索、下单
- 相似用户/相似Item
- 用户画像





关注QCon微信公众号，
获得更多干货！

Thanks!



主办方 **Geekbang** > **InfoQ**
极客邦科技